



Pendahuluan

Di tahun 2025, Indonesia memiliki **luas hutan** sebesar **118,2 juta hektare** indikasi **luas karhutla** mencapai **343.431,90 hektare** (Kemenhut 2025). Salah satu upaya pemulihan ekosistem adalah penilaian tingkat keparahan kebakaran hutan dan lahan. Karena penilaian oleh manusia rawan terhadap *human error* (Arrafi *et al* 2022), diperlukan solusi **otomatis yang tetap andal**, salah satunya adalah klasifikasi citra dengan CNN. Namun, umumnya, akurasi **model CNN sejalan dengan kompleksitas model**.

Akan tetapi, penelitian Arif (2025) menunjukkan bahwa MobileNetV2 (8,64 MB) berhasil mencapai akurasi uji 68%, tidak berbeda jauh dengan InceptionV3 yang berukuran 9,64 kali lipat lebih besar (83,21 MB) dan mencapai akurasi uji 76%. Temuan inilah yang menjadi dasar tujuan penelitian ini, yaitu **merancang model** klasifikasi pascakarhutla yang **efisien secara komputasi namun akurat**.



Metodologi

1. Pengumpulan Data

Sumber data: **penelitian Arif (2025)** sebanyak **1.626 citra** dan **pengumpulan mandiri** sebanyak **616 citra** (619 citra sebelum dilakukan perbaikan file)
TOTAL = 2.242 citra

3. Praproses Data

Lakukan **resizing**, **normalisasi**, dan **augmentasi** (**horizontal flipping**, **random rotation**, dan **random brightness adjustment**). **Faktor rotasi** dan **brightness adjustment** masing-masing sebesar **0,3**

5. Pembangunan Model

Arsitektur CNN yang digunakan adalah **MobileNet V3-Small**, **SqueezeNet V1.1**, **ShuffleNetV2-x0.5**, dan **EfficientNet-Lite0**. Dalam membangun model, **load pretrained weight** tiap model terlebih dahulu. Kemudian, modifikasi lapisan **fully-connected** untuk membuat jumlah kelas menjadi lima dan lapisan **dropout** untuk penyesuaian nilai **dropout**

2. Pelabelan Data

Fitur citra diekstrak menggunakan **VGG19**, kemudian dikelompokkan ke lima **cluster** menggunakan **k-means clustering**. **Kualitas cluster** diukur menggunakan **silhouette index** (SI). Kemudian, dilakukan **label assignment** pada tiap **cluster** berdasarkan buku Syaufina *et al* (2023) pada tiga gambar dengan skor SI tertinggi menggunakan indikator kondisi vegetasi dan tanah

4. Pembagian Data

Data dibagi menjadi tiga, yakni **pelatihan (70%)**, **validasi (20%)**, dan **uji (10%)**. Agar hasil augmentasi tidak mendominasi di satu partisi, versi augmentasi dari tiap gambar dimasukkan ke partisi yang sama dengan gambar orisinal

6. Pelatihan Baseline Model

Arsitektur CNN yang digunakan adalah **MobileNet V3-Small**, **SqueezeNet V1.1**, **ShuffleNetV2-x0.5**, dan **EfficientNet-Lite0**. Dalam membangun model, **load pretrained weight** tiap model terlebih dahulu. Kemudian, modifikasi lapisan **fully-connected** untuk membuat jumlah kelas menjadi lima dan lapisan **dropout** untuk penyesuaian nilai **dropout**

7. Hyperparameter Tuning

Hyperparameter	Kombinasi	Metode yang digunakan adalah grid search . Proses dilakukan menggunakan GPU RTX-2060 6 GB dan diulang selama 100 epoch
Batch size	8, 16, 32	
Dropout	0,3; 0,5	
Optimizer	Adam, RMSProp	
Learning Rate	0,001; 0,0001	
L1 Lambda	0,01; 0,001	
L2 Lambda	0,01; 0,001	

8. Evaluasi Model

Performa Model

$$F1 - \text{Score of Class } C_i = 2 \times \frac{TPR(C_i) \times PPV(C_i)}{TPR(C_i) + PPV(C_i)}$$

$$F1 - \text{Score (micro average)} = 2 \times \frac{TPR(\text{micro}) \times PPV(\text{micro})}{TPR(\text{micro}) + PPV(\text{micro})}$$

$$F1 - \text{Score (macro average)} = 2 \times \frac{TPR(\text{macro}) \times PPV(\text{macro})}{TPR(\text{macro}) + PPV(\text{macro})}$$

$$\text{Akurasi} = \frac{\sum_{i=1}^N TP(C_i)}{\sum_{i=1}^N \sum_{j=1}^N C_{i,j}}$$

$$\text{Recall of Class } C_i = \frac{TP(C_i)}{TP(C_i) + FN(C_i)}$$

$$\text{Recall (micro average)} = \frac{\sum_{i=1}^N TP(C_i)}{\sum_{i=1}^N [TP(C_i) + FP(C_i)]}$$

$$\text{Recall (macro average)} = \frac{1}{N} \sum_{i=1}^N TPR(C_i)$$

$$\text{Precision of Class } C_i = \frac{TP(C_i)}{TP(C_i) + FP(C_i)}$$

$$\text{Precision (micro average)} = \frac{\sum_{i=1}^N RP(C_i)}{\sum_{i=1}^N [TP(C_i) + FP(C_i)]}$$

$$\text{Precision (macro average)} = \frac{1}{N} \sum_{i=1}^N PPV(C_i)$$

Efisiensi Model

Waktu pelatihan dan validasi selama 100 epochs

Ukuran Model = Jumlah Parameter $\times$ 4



Hasil dan Pembahasan

Best Hyperparameter

Model	Hyperparameter				
	Batch size	Dropout	Learning rate	L1 lambda	L2 lambda
MobileNet V3-Small	8	0,3	0,0001	0,01	0,001
SqueezeNet V1.1	16	0,5	0,0001	0,001	0,01
ShuffleNetV2-x0.5	16	0,3	0,001	0,001	0,01
EfficientNet-Lite0	32	0,3	0,0001	0,01	0,001


Performa Per Kelas



Performa Keseluruhan Terbaik

Jenis Model	Arsitektur Terbaik	Akurasi Uji	F1-Score	
			F1-Score macro	F1-Score micro
Baseline Model	MobileNet V3-Small	0,52	0,53	0,52
	Efficientnet-Lite0	0,54	0,53	0,54
Best Model	SqueezeNet V1.1	0,56	0,56	0,56
	ShuffleNetV2-x0.5	0,54	0,55	0,56

Efisiensi Model



Kesimpulan & Saran

Kesimpulan

Model yang paling sesuai untuk menjawab tujuan dari penelitian ini adalah **SqueezeNet V1.1** dengan kinerja unggul dan efisien (waktu dan ukuran model)

Saran

Memperkaya dataset, khususnya untuk kelas-kelas dengan jumlah citra yang sedikit, sehingga menjamin keberagaman dataset dan menjaga keseimbangan data setiap kelas

TTD

Prof. Dr. Imas Sukaesih Sitanggang, S.Si., M.Kom.

Hari Agung Adrianto, S.Kom., M.Si., Ph.D.